巨量資料分析與應用 - 作業二 (HW2) 完整對話紀錄

本文件記錄了使用者與 AI 助手在完成 **作業二：多元線性迴歸分析 (Multiple Linear Regression, CRISP-DM)** 過程中的所有對話、需求討論、版本疊代與除錯歷程。

- **課程名稱**：巨量資料分析與應用
- **作業主題**：HW2: Multiple Linear Regression (多元線性迴歸)
- **選用資料集**：Kaggle - House Sales in King County, USA (18 個特徵)
- **產出主要檔案**：
  - `HW2_Multiple_Linear_Regression.py` （Python 執行腳本）
  - `HW2_Multiple_Linear_Regression.ipynb` （Jupyter Notebook）
  - `HW2_Report.md` （Markdown 報告）
  - `HW2_Report.html` （含 MathJax 渲染與一鍵列印 PDF 的 HTML 報告）
  - `figures/` （8 張高解析分析圖表）

📑 對話目錄

1. 回合一：作業需求解析與初版建置 (醫療保險資料集)
2. 回合二：報告開啟與 PDF 另存操作指引
3. 回合三：新版規格檢核與全面重構 (切換為 King County 房價 18 特徵與 CRISP-DM 流程)
4. 回合四：HTML 數學公式與表格排版異常排查與修復
5. 回合五：對話歷史轉存為 Markdown 紀錄

回合一：作業需求解析與初版建置

👤 使用者 (User)

> **訊息內容：**
> 幫我做作業
>
> *(附圖：LMS 系統之作業二公告截圖，題目為「HW2: Multiple Linear regression」，說明多元線性迴歸評分指標，推薦 Kaggle 4~15 特徵之資料集清單，其中老師 Top 3 教學推薦首選為 Medical Cost Personal Datasets 醫療費用預測)*

🤖 AI 助手 (Assistant) - 互動選項確認

AI 助手分析截圖後，透過選項引導使用者確認資料集與輸出格式偏好：

- **問題 1**：作業清單中推薦了數個 Kaggle 資料集，請問您偏好使用哪一個資料集進行多元線性迴歸分析？
  👉 **使用者選擇：** `(Recommended) Medical Cost Personal Datasets`（醫療費用預測，老師推薦首選，含年齡、BMI、抽菸等 6 個特徵，迴歸解釋性極高）
- **問題 2**：您希望產出哪些繳交檔案格式？
  👉 **使用者選擇：** `(Recommended) 獨立 Python 腳本 (.py)`（可直接終端執行並生成所有圖表）

🤖 AI 助手 (Assistant) - 成果交付

作業二（**HW2: Multiple Linear Regression 多元線性迴歸分析**）已全數製作完成！

本作業依據老師在課堂說明的評分標準與推薦清單，選用 Kaggle 最經典且具備極高解釋性的 **醫療保險費用預測資料集 (`insurance.csv`)**，特徵數為 6 個（完全符合 4~15 個 Features 的要求）。

📁 交付檔案清單（已存放於專案資料夾）

1. **HW2_Multiple_Linear_Regression.py**
   - 獨立且完整的 Python 執行腳本。包含資料載入、EDA、類別編碼、特徵縮放、五大模型訓練評估、高斯-馬可夫四大假設統計檢驗，並自動輸出 7 張 300 DPI 高畫質圖表至 `figures/` 資料夾。
2. **HW2_Multiple_Linear_Regression.ipynb**
   - 完整 Jupyter Notebook，包含 Markdown 說明、分段程式碼與結構。
3. **HW2_Report.md**
   - 詳細的作業成果分析書面報告，嚴格對標教師五大評分維度（EDA、模型訓練、評估比較、圖表視覺化、係數商業詮釋）。
4. **HW2_Report.html**
   - 美觀排版的 HTML 報告，內建「🖨️ 列印 / 另存為 PDF」按鈕，可在瀏覽器（Edge / Chrome）一鍵輸出為 PDF。
5. **figures/**
   - 7 張高品質分析圖表（分佈圖、相關係數熱力圖、吸菸與 BMI 交互效應圖、各模型指標柱狀圖、殘差診斷四格圖、預測散佈圖、標準化係數圖）。
6. **insurance.csv**
   - 資料集（1,338 筆樣本，包含年齡、性別、BMI、子女數、抽菸、地區及醫療費用）。

📊 核心實驗結果摘要

模型 (Model)	訓練集 R^2	測試集 R^2	測試集 Adj R^2	測試集 RMSE ($)	測試集 MAE ($)	模型特性與評析
多元線性迴歸 (Baseline OLS)	0.7417	0.7836	0.7769	$5,796.28	$4,181.19	基準模型，表現穩健
Ridge 嶺迴歸 (L2)	0.7417	0.7835	0.7769	$5,796.98	$4,182.80	平滑權重，抑制共線性
Lasso 套索迴歸 (L1)	0.7417	0.7836	0.7769	$5,796.65	$4,181.51	L1 稀疏性特徵篩選
ElasticNet 彈性網絡	0.7400	0.7793	0.7725	$5,853.88	$4,275.66	L1 + L2 混合正則化
⭐ 交互項多元迴歸 (OLS + BMI*Smoker)	**0.8341**	**0.8653**	**0.8605**	**$4,573.81**	**$2,756.90**	**表現最優（RMSE 降低 21.1%，MAE 降低 34.1%）**

🔍 關鍵統計發現與商業意涵（符合作業要求亮點）

1. **抽菸與肥胖的「超加乘爆炸性」交互效應**（`bmi_smoker`，$t = 24.29, p < 0.0001$）：
   - 呼應老師在作業說明特別提示的重點：非抽菸者即使 BMI 增加，醫療費用上升幅度溫和；然而**一旦為吸菸者且 BMI > 30（肥胖），醫療費用呈斷崖式暴增**（年支出高達 $30,000 ~ $60,000 美元），加入交互特徵使整體 R^2 躍升至 **0.8653**。
2. **年齡效應**（`age`，$t = 24.36, p < 0.0001$）：
   - 在控制其他條件下，被保險人每增長 1 歲，平均醫療支出增加約 **$263.39 美元**，客觀反映衰老帶來的慢性病發病機率。
3. **高斯-馬可夫假設檢驗完全通過**：
   - **無多元共線性**：所有特徵之 VIF 均小於 1.62（遠低於警戒門檻 5）。
   - **誤差獨立性**：Durbin-Watson 統計量為 **2.0734**（極接近 2.0，確認無自相關）。
   - **同質變異**：Breusch-Pagan 檢定 $p = 0.3923 > 0.05$，未違反同質變異假設。
4. **保險核保策略建議**：
   - 建議保險公司推動「外溢型健康促進保單」，提供保戶戒菸與體重管理保費折扣，降低高額理賠風險。

🚀 如何執行與查看成果

- **在終端直接執行 Python 腳本：**

```
python HW2_Multiple_Linear_Regression.py
```

- **查看與匯出報告：** 雙擊打開 `HW2_Report.html` ，點擊右下角「**列印 / 另存為 PDF**」，即可取得排版完成的作業書面報告 PDF。

回合二：報告開啟與 PDF 另存操作指引

👤 使用者 (User)

> **訊息內容：**
> 我執行後，怎麼雙擊打開 HW2_Report.html?

🤖 AI 助手 (Assistant)

您可以透過以下幾種方式輕鬆打開 HW2_Report.html：

方法一：從 Windows 桌面資料夾「雙擊打開」（最直覺）

1. 回到 Windows **桌面 (Desktop)**。
2. 找到並進入資料夾： `HW2 Multiple Linear regression` 。
3. 在資料夾內找到 **`HW2_Report.html`** （圖示通常會是 Edge 或 Chrome 的網頁圖示）。
4. **對它連按兩下滑鼠左鍵（雙擊）**，系統就會自動以瀏覽器開啟完整的排版報告。

方法二：在編輯器左側檔案清單中開啟

1. 看向編輯器**左側的檔案總管（Explorer）側邊欄**。
2. 找到 `HW2_Report.html` 。
3. **在檔名上按滑鼠右鍵**，選擇：
   - **「在檔案總管中顯示 (Reveal in File Explorer)」**：會直接幫您彈出 Windows 資料夾並選中該檔案，接著直接雙擊即可。
   - 或選擇 **「在預設瀏覽器中開啟 (Open with Default Browser)」**。

方法三：在終端機（Terminal）輸入一行指令直接叫出瀏覽器

如果您當前已經在終端機視窗中，直接輸入以下指令按 Enter，系統就會立刻幫您用瀏覽器彈出該報告：

```
Start-Process HW2_Report.html
```

💡 如何另存為 PDF 繳交？

1. 網頁開啟後，報告內已嵌入所有統計數據表格與 7 張分析圖表。
2. 點擊頁面右下角的藍色浮動按鈕 **「🖨️ 列印 / 另存為 PDF」**（或按鍵盤快捷鍵 `Ctrl + P` ）。

3. 印表機目的地選擇 **「另存為 PDF (Save as PDF)」**。
4. 點擊「儲存」，即可取得繳交格式的作業分析報告 PDF。

回合三：新版規格檢核與全面重構

使用者 (User)

> **訊息內容：**
> 檢查目前作業是否符合附圖這幾項。
> 提供你選擇的kaggle網址給我，並檢查是否符合14-39 features。
> 請將作業中的公式用數學式寫好，不要用程式碼的寫法。
> 作業網址如下:
> file:///C:/Users/88693/Desktop/HW2%20Multiple%20Linear%20regression/HW2_Report.html
>
> *(附圖：作業規格補充說明截圖，重點包含：*
> *1. 資料來源：Kaggle 10 至 20 個特徵之公開資料集，明確標示來源與連結。*
> *2. 分析任務：使用線性迴歸，**必須執行特徵選擇 (Feature Selection) 與模型評估**，結果需包含**預測圖(加上信賴區間或預測區間)**。*
> *3. CRISP-DM 流程說明：Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation, Deployment。)*

AI 助手 (Assistant)

已為您逐項檢核作業要求，並全面升級為符合**最新規範**與**附圖所有細節**的全新版本！

一、作業規範逐項檢核對照表

附圖要求項目	原先狀態	現況調整與檢核結果	判定
1. 資料來源與特徵數（10 至 20 個特徵 / 14~39 features，註明 Kaggle 連結）	原醫療資料集僅 6 個特徵，不符規範	**已更換為 Kaggle 經典房價資料集**，扣除流水號與目標變數後**共計 18 個特徵**，完美落於 10~~20 個特徵（且符合 14~~39 features）區間內，並於報告首頁明確標示 Kaggle 官方連結。	**通過 (100%)**
2. 特徵選擇 (Feature Selection)（作業規定「必須執行」）	原僅有正則化係數懲罰	**實作 RFE（遞迴特徵消除法）與 Lasso 稀疏篩選**，精選出 12 個核心特徵，並產出「全特徵 vs 特徵選擇後精簡模型」之 R^2、RMSE、MAE 對比長條圖與指標表。	**通過 (100%)**
3. 預測圖含區間（需加上信賴區間或預測區間）	原僅有一般預測散佈圖	**新增圖 6：繪製專屬預測圖**，同時包含 **95% 期望值信賴區間 (Confidence Interval)**、**95% 個體值預測區間 (Prediction Interval)** 與測試集實際成交價散佈點。	**通過 (100%)**
4. CRISP-DM 流程說明（依循六大標準階段開展）	原採傳統五大步驟	**全面改寫為 CRISP-DM 六大階段**：Business Understanding $\rightarrow$ Data Understanding $\rightarrow$ Data Preparation $\rightarrow$ Modeling $\rightarrow$ Evaluation $\rightarrow$ Deployment。	**通過 (100%)**
5. 數學公式表示法（不要用程式碼寫法）	原含有部分代碼化表示	**全面改以學術標準 $\LaTeX$ 數學式呈現**，並在 HTML 報告中導入 **MathJax 3 渲染引擎**，所有公式均以高質感數學方程式排版展現。	**通過 (100%)**

二、所選 Kaggle 資料集與特徵數量檢核

- **資料集名稱**：House Sales in King County, USA (`kc_house_data.csv`)
- **Kaggle 官方來源網址**：https://www.kaggle.com/datasets/harlfoxem/housesalesprediction
- **特徵數量驗證**：
  - 資料集共有 21 個欄位，排除識別碼 `id` 、日期 `date` 以及預測目標 `price` 。
  - **實際可用預測特徵共 18 個**： `bedrooms` , `bathrooms` , `sqft_living` , `sqft_lot` , `floors` , `waterfront` , `view` , `condition` , `grade` , `sqft_above` , `sqft_basement` , `yr_built` , `yr_renovated` , `zipcode` , `lat` , `long` , `sqft_living15` , `sqft_lot15`
  - **檢核結果**：**18 個特徵** 完全符合附圖要求之「**10 至 20 個特徵 (features)**」，亦完全滿足您的「**14-39 features**」要求。

三、報告中主要公式之標準數學式呈現

在 HW2_Report.md 與 HW2_Report.html 中，所有公式均已使用標準數學式改寫：

1. 多元線性迴歸母體模型

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i, \quad \varepsilon_i \overset{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)$$

2. 最小平方法 (OLS) 矩陣解

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

3. 評估指標 (RMSE, MAE, R^2, 調整後 R^2)

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}*i)^2}, \quad \text{MAE} = \frac{1}{n} \sum*{i=1}^n |y_i - \hat{y}_i|$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}*i)^2}{\sum*{i=1}^n (y_i - \bar{y})^2}, \quad R^2_{\text{adj}} = 1 - (1 - R^2) \frac{n - 1}{n - p - 1}$$

4. ⭐ 95% 信賴區間 (Confidence Interval for Mean Response $E(y_0)$)

$$\hat{y}*0 \pm t*{\alpha/2, , n-p-1} \cdot s_e \sqrt{\mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0}$$

5. ⭐ 95% 預測區間 (Prediction Interval for Individual Observation y_0)

$$\hat{y}*0 \pm t*{\alpha/2, , n-p-1} \cdot s_e \sqrt{1 + \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0}$$

6. 正則化損失函數 (Ridge, Lasso)

$$\hat{\boldsymbol{\beta}}*{\text{Ridge}} = \arg\min*{\boldsymbol{\beta}} \left{ \sum_{i=1}^n (y_i - \mathbf{x}*i^T \boldsymbol{\beta})^2 + \lambda \sum*{j=1}^p \beta_j^2 \right}$$

$$\hat{\boldsymbol{\beta}}*{\text{Lasso}} = \arg\min*{\boldsymbol{\beta}} \left{ \sum_{i=1}^n (y_i - \mathbf{x}*i^T \boldsymbol{\beta})^2 + \lambda \sum*{j=1}^p |\beta_j| \right}$$

四、最新產出檔案與檢視連結

1. **HTML 完整網頁報告（含 MathJax 數學方程式與列印 PDF 功能）**：
   - 檔案路徑：HW2_Report.html
   - 可在終端機輸入 `Start-Process HW2_Report.html` ，或直接雙擊檔案，瀏覽器即可載入數學公式排版與 8 張高畫質圖表。
2. **完整 Python 執行腳本**：
   - 檔案路徑：HW2_Multiple_Linear_Regression.py

- 執行指令： `python HW2_Multiple_Linear_Regression.py` （已實測執行完畢，代碼退出碼為 0）。

3. **Jupyter Notebook 檔案**：
   - 檔案路徑：HW2_Multiple_Linear_Regression.ipynb
4. **Markdown 格式報告**：
   - 檔案路徑：HW2_Report.md
5. **圖表目錄**：
   - figures/ 包含 8 張高解析（300 DPI）圖表，其中 **`fig6_prediction_intervals.png`** 即為符合附圖要求的「信賴區間與預測區間預測圖」。

回合四：HTML 數學公式與表格排版異常排查與修復

使用者 (User)

> **訊息內容：**
> 修正後續的數學公式(從附圖開始)
>
> *(附圖：使用者以瀏覽器開啟 `HW2_Report.html` 之畫面截圖，顯示在「三、Phase 3: 資料準備與特徵工程」3.2 節中，特徵標準化公式未被渲染，呈現為原始字串 `$$z_{ij} = \frac{x_{ij} - \bar{x}j}{s_j}...$$`)*

AI 助手 (Assistant)

已全面修正自 **Phase 3（附圖處）起至報告結尾** 的所有數學公式與表格排版問題！

問題原因診斷與修正說明

1. **下標與加總符號解析衝突修復**：
   - 原先 Markdown 轉換器將公式中的下標 `_j` 、 `_i` 及加總 `\sum_{i=1}^n` 誤判為斜體標籤（變成 `<em>j</em>` ），破壞了 LaTeX 語法結構，導致瀏覽器中的 MathJax 無法正常辨認而顯示成原始文本。
   - **修正**：已建立公式保護機制，確保所有 `$$...$$` 與 `$...$` 在轉換過程中保持純淨的 $\LaTeX$ 原貌，交由 **MathJax 3** 進行標準方程式排版渲染。
2. **5.6 節推論統計表格分隔線修復**：
   - 原先表格標頭中的 `$P > |t|$` 其絕對值符號 `|` 被 Markdown 誤判為表格欄位分隔線（Pipe），導致整張表格破版變為純文字。
   - **修正**：已將絕對值符號轉義為 `\|t\|` ，表格已完全恢復為對齊的標準 HTML 表格。

修正後的重點數學公式對照清單（Phase 3 起）

1. Phase 3.2：特徵標準化公式 (Z-score Standardization)

$$z_{ij} = \frac{x_{ij} - \bar{x}*j}{s_j}, \quad \text{其中 } \bar{x}j = \frac{1}{n} \sum{i=1}^n x{ij}, \quad s_j = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2}$$

2. Phase 4.1：模型目標與正則化損失函數

- **全特徵多元線性迴歸 (Baseline OLS)**： $$\min_{\boldsymbol{\beta}} \sum_{i=1}^n (y_i - \mathbf{x}_i^T \boldsymbol{\beta})^2$$
- **嶺迴歸 (Ridge, L2 正則化)**： $$\min_{\boldsymbol{\beta}} \left{ \sum_{i=1}^n (y_i - \mathbf{x}*i^T *boldsymbol{\beta})^2 + \lambda \sum{j=1}^p \beta_j^2 \right} \implies \hat{\boldsymbol{\beta}}_{\text{Ridge}} = (\mathbf{X}^T \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^T \mathbf{y}$$

- **套索迴歸 (Lasso, L1 稀疏特徵選擇)**： $$\min_{\boldsymbol{\beta}} \left{ \sum_{i=1}^n (y_i - \mathbf{x}*i^T \boldsymbol{\beta})^2 + \lambda \sum*{j=1}^p |\beta_j| \right}$$
- **彈性網絡迴歸 (ElasticNet)**： $$\min_{\boldsymbol{\beta}} \left{ \sum_{i=1}^n (y_i - \mathbf{x}*i^T \boldsymbol{\beta})^2 + \lambda \left(\alpha \sum*{j=1}^p |\beta_j| + \frac{1-\alpha}{2} \sum_{j=1}^p \beta_j^2 \right) \right}$$

3. Phase 5.1：模型評估指標

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}*i)^2}, \quad \text{MAE} = \frac{1}{n} \sum*{i=1}^n |y_i - \hat{y}_i|$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}*i)^2}{\sum*{i=1}^n (y_i - \bar{y})^2}, \quad R^2_{\text{adj}} = 1 - (1 - R^2) \frac{n - 1}{n - p - 1}$$

4. Phase 5.4：預測圖之區間推導（95% 信賴區間與預測區間）

- **點預測值**： $$\hat{y}_0 = \mathbf{x}_0^T \hat{\boldsymbol{\beta}}$$
- **95% 期望值信賴區間 (Confidence Interval for Mean Response $E(y_0)$)**： $$\text{CI}_{1-\alpha} = \hat{y}*0 \pm t*{\alpha/2, , n-p-1} \cdot s_e \sqrt{\mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0}$$
- **95% 個體值預測區間 (Prediction Interval for Individual Observation y_0)**： $$\text{PI}_{1-\alpha} = \hat{y}*0 \pm t*{\alpha/2, , n-p-1} \cdot s_e \sqrt{1 + \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0}$$

5. Phase 5.5：假設檢定指標

- **Durbin-Watson 獨立性檢定統計量**： $$d = \frac{\sum_{i=2}^n (e_i - e_{i-1})^2}{\sum_{i=1}^n e_i^2} = 1.9939$$
- **變異數膨脹因子 (VIF)**： $$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

🚀 立即檢視更新成果

HW2_Report.html 已同步重新編譯完畢。

您只需在原本開啟的瀏覽器分頁中按 **F5 （重新整理網頁）**，或在終端機執行：

```
Start-Process HW2_Report.html
```

所有公式即會以數學符號排版呈現，表格與圖表亦完整就位。

回合五：對話歷史轉存為 Markdown 紀錄

使用者 (User)

> **訊息內容**：
> 幫我把和你的所有對話轉成.md

AI 助手 (Assistant)

> 已將我們所有的對話內容、需求疊代歷程、技術細節與問題修復過程完整整理並匯出至本檔案 `chat_log.md` 。